多模态大模型原理与应用

2026春季学期期末大作业说明

课程名称： 多模态大模型原理与应用
学期： 2025-2026 春季学期
发布日期： 2026年4月9日

一、作业基本要求

1.1 组队与时间安排

- **组队规模：** 每组1-3人
- **期中开题：** 第9-10周，提交开题报告（约5页）+上台展示，包含：
  - 任务定义与应用背景
  - 相关工作调研（至少5篇代表性论文/项目）
  - 系统方案设计（架构图、模型选择、评测指标）
  - 初步数据集与实验设想（算力预算、时间计划）
- **期末验收：** 第16-17周，提交最终报告（10-15页）+ 上台展示，包含：
  - 系统实现细节与代码仓库
  - 定量实验结果（至少1-2项指标）+ 可视化/错误分析
  - 反思与展望（模型局限、AGI视角下的潜力与瓶颈）

1.2 评分标准

评分项	权重	说明
开题报告	20%	调研深度、方案可行性、工作量规划
系统实现	30%	代码质量、功能完整性、创新性
实验评测	20%	实验设计合理性、指标选择、结果分析
最终汇报	30%	Demo演示效果、报告清晰度、团队协作

1.3 算力与资源说明

- **推荐算力：** 大部分题目可在1张24GB消费级GPU（如RTX 3090/4090）或云平台免费额度内完成
- **云平台选项：** 中大超算、Google Colab Pro、阿里云、AutoDL等
- **开源模型优先：** 鼓励使用Qwen2.5-VL、LLaMA 3.2 Vision、BLIP-2等开源模型

二、题目列表（仅供参考，可以自由选题）

题目1：基于VLM的智能图文问答助手

任务描述

构建一个"看图/看文档能聊天"的多模态助手，支持商品图+问题、讲义截图+问题等场景。要求支持至少两类图像（自然场景、文档/幻灯片），实现中文问答和基础推理功能。

推荐技术栈

- **模型选择：** Qwen2.5-VL（7B）、LLaMA 3.2 Vision、Gemma 3-Vision、GLM-4.6V-Flash
- **训练方式：** 推理为主 + 可选LoRA微调
- **评测数据集：** VQA-v2子集、TextVQA、自建中文图文问答集

算力要求

- **GPU：** 1×24GB（如RTX 3090）或云端推理API

最低验收标准

- 支持上传图片+文本问题，返回多轮对话式回答
- 实现Web UI或命令行交互界面
- 在至少一个公开数据集子集上评测，报告准确率或人工打分结果
- 提供5-10个典型成功/失败案例分析

参考工作与代码仓库

- CLIP/BLIP/BLIP-2：图文预训练与问答基础架构
- LLaVA、MiniGPT-4：开源图文对话框架
- Qwen-VL官方仓库：https://github.com/QwenLM/Qwen-VL
- 开源VLM综合对比：Best Open Source Multimodal Vision Models (2025)

题目2：面向课堂视频的多模态问答机器人

任务描述

针对教学视频（课程录播、公开课），构建"看视频+听音频+看字幕"的问答/检索机器人。

例如："老师在12分钟左右板书了哪几个要点？"

推荐技术栈

- **语音转文本：** Whisper、FunASR
- **视频理解：** VideoChat、VideoChatGPT、Qwen-VL（视频模式）
- **检索增强：** 向量数据库（FAISS、Milvus）+ 时间戳索引

算力要求

- **GPU：** 1×16-24GB（视频可抽帧降采样）

最低验收标准

- 支持用户输入视频链接或本地视频文件
- 自动抽帧（如1 FPS）+ 音频转写，构建多模态索引
- 用户可就视频内容提问，系统返回带时间戳引用的回答
- 至少在3-5个教学视频上完成测试，展示问答准确性

参考工作与代码仓库

- VideoChat/VideoChatGPT
- Whisper官方仓库：https://github.com/openai/whisper
- LangChain视频问答教程：Building multimodal AI applications
- VideoChat论文：https://arxiv.org/abs/2305.06355

题目3：文档理解+多模态检索问答系统

任务描述

针对PDF、扫描文档、PPT截图等，构建"文档智能助手"。用户上传文档或页面截图，系统可定位表格/图像/公式区域，回答结构化问题（如"图3表示什么趋势？"、"第2节主要结论是什么？"）。

推荐技术栈

- **模型选择：** LLaMA 3.2 Vision、Qwen2.5-VL、DeepSeek-VL（强文档能力）
- **OCR增强：** PaddleOCR、Tesseract（可选）
- **RAG架构：** LangChain + 向量检索对长文档分块

算力要求

- **GPU：** 1×24GB或云端API

最低验收标准

- 支持上传多页PDF或图像，自动分块（文本/表格/图形）
- 支持自然语言问题查询，在回答中标出引用的页面/图号
- 在至少一个文档数据集（DocVQA、ChartQA子集或自建）上评测
- 对比纯文本RAG与多模态RAG的效果差异

参考工作与代码仓库

- TextVQA、DocVQA、ChartQA数据集
- Qwen2.5-VL文档理解能力评测
- LangChain多模态RAG示例：https://python.langchain.com/docs/use_cases/visual_qa
- DeepSeek-VL：https://github.com/deepseek-ai/DeepSeek-VL

题目4：图文驱动的个性化封面/海报生成

任务描述

基于扩散模型或开源文本到图像模型，构建"智能设计助手"。输入文案、风格参考图（或草图），自动生成个性化海报/书籍封面/课程封面，并支持少量交互式修改。

推荐技术栈

- **生成模型：** Stable Diffusion、SDXL、HCP-Diffusion
- **控制方法：** LoRA微调、ControlNet（边缘/深度图）、DreamBooth
- **前端界面：** Gradio、Streamlit或HCP-Diffusion Web UI

算力要求

- **GPU：** 1×24GB（可使用低显存优化方案）

最低验收标准

- 至少支持两种控制方式：文本提示词 + 参考图（布局草图/风格图）
- 提供简单Web UI供用户交互式生成与调整
- 设计一套小型评测：人工主观打分（美观度、符合度）或CLIP Score、FID等自动指标
- 对比不同提示策略或LoRA微调前后的生成效果

参考工作与代码仓库

- HCP-Diffusion：高效扩散模型训练与部署
- Stable Diffusion官方：https://github.com/Stability-AI/stablediffusion
- ControlNet论文与代码：https://github.com/lllyasviel/ControlNet
- LoRA微调教程：https://huggingface.co/docs/diffusers/training/lora

---

题目5：游戏或仿真环境中的多模态智能Agent

任务描述

选择一个简单2D/3D环境（如GridWorld、自制小迷宫，或轻量级AI2-THOR/Habitat子任务），构建"视觉+语言"导航/交互Agent。给定自然语言指令与视觉观测，Agent规划并执行动作（例如："走到红色椅子旁边"）。

推荐技术栈

- **仿真环境：** AI2-THOR、Habitat-Sim、iGibson（可选轻量子任务）
- **模型架构：** 小型LLM（7B）+ 简单强化学习（PPO、DQN）或规则控制
- **视觉编码：** CLIP特征 + 目标检测（YOLO、SAM）

算力要求

- **GPU：** 1×16-24GB（主要吃CPU/GPU混合，环境模拟较重）

最低验收标准

- 完成1-2种任务（如目标导航ObjectNav、简单交互）
- 报告成功率、SPL（Success weighted by Path Length）等指标[8]
- 提供至少10个episode的可视化轨迹与失败案例分析
- 对比纯视觉导航与"视觉+语言"导航的性能差异

参考工作与代码仓库

- AI2-THOR官方：https://ai2thor.allenai.org/
- Habitat-Sim：https://github.com/facebookresearch/habitat-sim
- RoboAgent、RT-1/RT-2具身智能模型
- Awesome Embodied Robotics & Agent：https://github.com/zchoi/Awesome-Embodied-Robotics-and-Agent

---

题目6：多模态教学/学习助手（图表+文字+语音）

任务描述

基于开源机械臂抓取/桌面操作场景（如Open-X-Embodied / Open X-CLAW风格数据或类似仿真环境），构建"视觉+语言指令→抓取/放置方案"的多模态系统。重点在多模态理解与动作规划，而不要求真正控制真实机器人。

推荐技术栈

- **感知模块：** Segment Anything (SAM)、YOLO、CLIP（物体检测与分割）
- **语言理解：** LLM解析任务指令（如GPT-3.5、Qwen）
- **规划模块：** 启发式规则或轻量Transformer学习"场景+指令→动作"映射
- **仿真环境：** PyBullet、Isaac Gym桌面场景（可选）

算力要求

- **GPU：** 1×16-24GB

最低验收标准

- 在仿真或离线数据中，选择至少50个不同桌面场景（物体组合不同）
- 设计≥60条任务指令（不同目标物体/数量/关系约束）
- 评估规划成功率（动作方案是否满足指令目标）
- 提供若干典型场景的可视化（物体分割、动作标注）及至少5个失败案例分析

参考工作与代码仓库

- Open X-Embodiment项目：https://robotics-transformer-x.github.io/
- Segment Anything (SAM)：https://github.com/facebookresearch/segment-anything
- RT-1/RT-2机械臂操作模型
- PyBullet仿真环境：https://pybullet.org/

题目7：网页多模态Agent（界面理解+自动操作）

任务描述

设计一个网页多模态Agent：基于网页截图/结构信息和自然语言指令，生成一系列浏览器操作（点击、输入、滚动）来完成具体任务。可在浏览器自动化环境中演示。

推荐技术栈

- **架构设计：** VLM（解析界面截图） + LLM（规划动作序列） + 工具调用
- **执行工具：** Selenium、Playwright（浏览器自动化）
- **状态管理：** 简单状态机或ReAct框架

算力要求

- **GPU：** 1×24GB（LLM推理 + 轻量VLM）

最低验收标准

- 选择1-2个真实网站，针对每个网站至少设计3个任务场景
- 每个场景至少10次独立测试（共≥60次），统计任务成功率
- 分类记录失败类型（识别失败/规划失败/执行失败）
- 提供可视化操作轨迹（截图序列+动作序列）及错误分析

参考工作与代码仓库

- OpenClaw、Nanobot等Agent
- Playwright官方：https://playwright.dev/
- SMART-LLM多Agent任务规划：https://github.com/SMARTlab-Purdue/SMART-LLM
- WebAgent研究综述与代码

题目8：具身智能/仿真导航多模态Agent

任务描述

在自制或开源仿真环境中（2D或简化3D），实现一个基于视觉和语言指令的导航/交互Agent，执行例如"到达目标物体旁边"等任务。强调强化学习/规划与多模态结合。

推荐技术栈

- **仿真环境：** 自制Gym-like迷宫、简化AI2-THOR/Habitat子任务
- **策略方法：** PPO、DD-PPO（强化学习）或LLM+规划混合方案
- **视觉编码：** CLIP特征 + 目标检测

算力要求

- **GPU：** 1×16-24GB（环境模拟+策略训练）

最低验收标准

- 至少50个测试关卡（随机生成或手工设计），指令多样化
- 报告成功率与SPL（Success weighted by Path Length）指标
- 对比"有语言指令 vs 只有坐标目标"的性能差异
- 提供至少10个episode的可视化轨迹与失败案例分析

参考工作与代码仓库

- AI2-THOR官方：https://ai2thor.allenai.org/
- Habitat-Sim：https://github.com/facebookresearch/habitat-sim
- RoboAgent、RT-1/RT-2具身智能模型[9][10]
- Awesome Embodied Robotics & Agent：https://github.com/zchoi/Awesome-Embodied-Robotics-and-Agent

---

三、通用评测指标与工具

3.1 常用评测指标

任务类型	推荐指标
VQA	准确率（Accuracy）、F1 Score
Image Caption	BLEU、ROUGE、CIDEr、METEOR
视频问答	准确率、时间戳精度
Agent导航	成功率、SPL、路径长度
AIGC生成	CLIP Score、FID、人工主观打分

Table 1: 常用评测指标汇总

3.2 推荐开发工具

- **深度学习框架：** PyTorch、TensorFlow
- **多模态库：** Hugging Face Transformers、LangChain、LlamaIndex
- **前端界面：** Gradio、Streamlit
- **向量检索：** FAISS、Milvus、Pinecone
- **数据标注：** Label Studio、CVAT

四、提交要求与注意事项

4.1 代码与文档要求

- **代码仓库：** 需提交GitHub仓库链接，包含README.md（环境配置、运行说明）
- **开题报告：** PDF格式，5页左右，模板见课程网站
- **最终报告：** PDF格式，15-20页，需包含：摘要、引言、相关工作、方法、实验、结论、参考文献
- **Demo视频：** 3-5分钟录屏演示（上传至B站/YouTube并提供链接）

4.2 学术诚信

- 允许使用开源代码与预训练模型，但需在报告中明确标注
- 禁止抄袭他人代码或报告
- 鼓励创新与改进，对开源工作的深度理解与扩展同样有价值